



# Regresión Lineal

Grupo Análisis Numérico y Financiero

Universidad de Antioquia

28 de agosto de 2015

# Outline

## 1 Regresión lineal con una variable

- Representación del modelo

- Algoritmo de gradiente descendiente

- Gradiente descendiente para regresión lineal

- Ejemplos

## 2 Regresión lineal múltiple

- Normalización

- Gradiente descendiente

## 3 Mínimos cuadrados

- Ajuste del modelo lineal

# Next Subsection

## 1 Regresión lineal con una variable

Representación del modelo

Algoritmo de gradiente descendiente

Gradiente descendiente para regresión lineal

Ejemplos

## 2 Regresión lineal múltiple

Normalización

Gradiente descendiente

## 3 Mínimos cuadrados

Ajuste del modelo lineal

## Regresión lineal con una variable

## Componentes

Se miden

## OBJETIVO

- variables *inputs*
- predictor
- variable independiente
- característica

Para encontrar

HACER

- variable *output*
- respuesta
- variable dependiente
- cualitativa o cuantitativa

## PREDICCIONES



## Regresión lineal con una variable

La distinción en el tipo de variable de salida ha llevado a una convención de nombre en las tareas de predicción:

- *regresión*: cuando se predicen *outputs* cuantitativas  $Y$ .
- *clasificación*: cuando se predicen *outputs* cualitativas  $G$ .

Estas dos tareas tienen mucho en común y, en particular, ambas se pueden ver como una tarea en aproximación de funciones.



# Regresión lineal con una variable

## Regresión lineal simple

La regresión lineal es un método matemático que modela la relación entre una variable dependiente, una variable independiente (regresores), y un término aleatorio  $\epsilon$ .

La función de hipótesis tiene una forma general expresada por

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

El término  $\theta_0$  es el intercepto, también conocido como *bias* en machine learning.

# Regresión lineal

## Modelo lineal múltiple

Dado un vector de *inputs*  $X^T = (X_1, X_2, \dots, X_p)$ , se predice el *output*  $Y$  vía el modelo

$$\hat{Y} = \hat{\theta}_0 + \sum_{j=1}^p X_j \theta_j$$

Usualmente conviene incluir la variable constante 1 en  $X$ , incluyendo  $\hat{\theta}_0$  en el vector de coeficientes  $\hat{\theta}$ , escribiendo el modelo lineal como un producto interno

$$\hat{Y} = X^T \cdot \hat{\theta}$$







# Regresión lineal

## Modelo lineal múltiple


Visto como una función sobre el  $p$ -dimensional espacio de *input*,

$$f(X) = X^T \theta$$

es lineal, y el gradiente

$$f'(X) = \theta$$

es un vector en el espacio de *inputs* que apunta en la dirección de ascenso más empinada.



# Regresión lineal

Notación: de aquí en adelante se usará la siguiente convención

$$\mathbb{X} = \begin{bmatrix} x_1^{(1)} & x_2^{(1)} & \dots & x_n^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \dots & x_n^{(2)} \\ \vdots & \vdots & & \vdots \\ x_1^{(i)} & x_2^{(i)} & \dots & x_n^{(i)} \\ \vdots & \vdots & & \vdots \\ x_1^{(m)} & x_2^{(m)} & \dots & x_n^{(m)} \end{bmatrix} = \begin{bmatrix} (x^{(1)})^T \\ (x^{(2)})^T \\ \vdots \\ (x^{(i)})^T \\ \vdots \\ (x^{(m)})^T \end{bmatrix} \quad y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(i)} \\ \vdots \\ y^{(m)} \end{bmatrix}$$


Cada dato es un vector en  $\mathbb{R}^n$  el cual se representa por medio de cada fila de la matriz.  $n$  es el número de características de cada ejemplo y  $m$  es el número de ejemplos.

# Regresión lineal con una variable

## Ejemplo

Para comprender el proceso de regresión lineal, se realiza un ejemplo en una variable.  $h_{\theta} = \theta_0 + \theta_1 x$

## Ejemplo



*Se desea encontrar una recta en el plano que mejor ajuste los datos*

$$y = \theta_0 + \theta_1 x.$$

# Regresión lineal con una variable

## Función de costo

### Definición


*La función de costo sirve para medir la precisión de la función de hipótesis.*

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m \left( h_{\theta}(x^{(i)}) - y^{(i)} \right)^2$$

*J es llamada función de error cuadrático o error cuadrático medio. El promedio de los errores cuadráticos se divide por dos con el fin de ejecutar el algoritmo de gradiente descendiente de manera más funcional.*

# Regresión lineal con una variable

## Superficie de la función de costo



## Next Subsection

## 1 Regresión lineal con una variable

## Representación del modelo

## Algoritmo de gradiente descendiente

## Gradiente descendiente para regresión lineal

## Ejemplos

## Normalización

## Gradiente descendente

## Ajuste del modelo lineal



# Regresión lineal con una variable

## Gradiente descendiente

El algoritmo de gradiente descendiente se usa para encontrar el mínimo de la función de costos.

El algoritmo consiste en iterar hasta obtener convergencia

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$


para  $j = 0, 1$ .



# Regresión lineal con una variable

## Gradiente descendiente

Contornos mostrando el mínimo de la función de costos.





# Regresión lineal con una variable

## Gradiente descendiente para regresión lineal

Repetir hasta obtener convergencia:

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m \left( (h_{\theta}(x^{(i)}) - y^{(i)}) x^{(i)} \right)$$





## Next Subsection

## Representación del modelo

## Algoritmo de gradiente descendente

## Gradiente descendiente para regresión lineal

## Ejemplos

## 2 Regresión lineal múltiple

## Normalización

## Gradiente descendente

## Ajuste del modelo lineal



## Regresión lineal con múltiples características

## Normalización

Quando sea necesario normalizar los datos se debe

- Sustraer el valor promedio de cada característica del conjunto en el conjunto de datos.
- Después de sustraer la media, se escala (se divide) el valor de las características por su respectiva desviación estándar.

La desviación estándar es una manera de medir la variación presente en un rango de valores de una característica en particular.



## Next Subsection

## Representación del modelo

## Algoritmo de gradiente descendente

## Gradiente descendiente para regresión lineal

## Ejemplos

## 2 Regresión lineal múltiple

## Normalización

## Gradiente descendiente

## Ajuste del modelo lineal





# Regresión lineal con múltiples características

## Gradiente descendiente

El algoritmo de gradiente descendiente implementado para el caso de una variable se puede generalizar al caso múltiple.

En el caso multivariado la función de costos se puede escribir de manera matricial como

$$J(\theta) = \frac{1}{2m} (X \theta - \vec{y})^T (X \theta - \vec{y})$$


donde

$$X = [(x^{(i)})^T] \quad \vec{y} = [y^{(i)}]$$

# Regresión lineal con múltiples características

## Selección de la tasa de aprendizaje $\alpha$

Se deben probar diferentes tasas de aprendizaje en el conjunto de datos para encontrar una tasa de aprendizaje que converja rápidamente. Si  $\alpha$  es muy grande  $J(\theta)$  puede diverger. Si  $\alpha$  es muy pequeña el gradiente descendiente demora en llegar al óptimo.









# Mínimos cuadrados

## Ajuste del modelo lineal

Para ajustar el modelo lineal a un conjunto de datos de entrenamiento por el método de mínimos cuadrados fijamos los coeficientes  $\theta$  que minimizan la suma de cuadrados de los residuos

$$RSS(\theta) = \sum_{i=1}^M (y_i - x_i^T \beta)^2.$$

$RSS(\theta)$  es una función cuadrática en los parámetros, y por tanto su mínimo siempre existe, pero puede que no sea único. En forma matricial

$$RSS(\theta) = (\vec{y} - X \beta)^T (\vec{y} - X \beta),$$

donde  $X$  es una matriz de orden  $m \times n$  con cada fila un vector *inputs*, y  $\vec{y}$  es un vector de *ouputs* de orden  $m \times 1$  en el conjunto de entrenamiento.

# Mínimos cuadrados

## Ecuaciones normales

Diferenciando con respecto a  $\beta$  en

$$RSS(\theta) = \sum_{i=1}^M (y_i - x_i^T \beta)^2,$$

se obtienen las ecuaciones normales:

$$X^T (\vec{y} - X \cdot \beta) = 0.$$

Si  $X^T X$  es no singular, entonces la única solución es

$$\hat{\beta} = (X^T X)^{-1} X^T \vec{y}.$$

# Mínimos cuadrados

## Ecuaciones normales

El valor que se predice para la  $i$ -ésima entrada  $x_i$  es

$$\hat{y}_i = \hat{y}(x_i) = x_i^T \cdot \hat{\beta}.$$

Y para un arbitrario *input*  $x_0$ , la predicción es

$$\hat{y}(x_0) = x_0^T \cdot \hat{\beta}.$$